

Getting Started with Japanese Corpora via NINJAL

David Honeycutt



UNIVERSITY of HAWAI'I at MĀNOA
DEPARTMENT of SECOND LANGUAGE STUDIES



Goals

- ▶ By the end of this workshop, you can run basic
→ advanced searches and export results for
frequency + n-gram analysis.

Audience

- ▶ Linguists new to Japanese corpora
- ▶ Those interested in Japanese NLP annotation

Today, you will...

1. Discover what corpora are available
2. Apply and/or log in
3. Search terms via the 日本語日常会話コーパス
(Corpus of Everyday Japanese Conversation)
4. Export results as a CSV
5. Do quick bigram/trigram analysis with Python code
(I will provide you with the code)

Workshop Files



What is Chunagon?

- ▶ Web application by NINJAL for searching Japanese corpora
- ▶ Supports simple string search and morphology-aware search (varies by corpus)
- ▶ Key idea: searches are often over tokenized / annotated units, not “words” as you’d intuit them



中納言

コーパス名	略 称	個別検索	まとめて検索	備 考
書き言葉 現代日本語書き言葉均衡コーパス	BCCWJ	✓	✓	従来より利用いただいている BCCWJ のデータです (コーパスの紹介ページ)。こちらのページから BCCWJ アノテーションデータをダウンロードできます。
話し言葉 日本語話し言葉コーパス	CSJ	✓	✓	コーパスの紹介ページ
話し言葉 日本語日常会話コーパス	CEJC	✓	✓	コーパスの紹介ページ 有償版契約者は関連データを「 データ配布 」からダウンロードできます。
話し言葉 子ども版日本語日常会話コーパス	CEJC-Child	✓	✓	コーパスの紹介ページ
話し言葉 昭和話し言葉コーパス	SSC	利用不可 〔 申込み方法 〕	利用不可 〔 申込み方法 〕	コーパスの紹介ページ SSC の全データ（音声・転記・形態論情報・メタデータ等）を こちら からダウンロードできます。ダウンロードするには、 コーパス追加利用の申請 から昭和話し言葉コーパスの新しい規約に同意して利用を申請してください。
話し言葉 名大会話コーパス	NUCC	✓	✓	コーパスの紹介ページ
話し言葉 現日研・職場談話コーパス	CWPC	✓	✓	コーパスの紹介ページ
通 時 日本語歴史コーパス	CHJ	利用不可 〔 申込み方法 〕	利用不可 〔 申込み方法 〕	コーパスの紹介ページ
通 時 昭和・平成書き言葉コーパス	SHC	利用不可 〔 申込み方法 〕	利用不可 〔 申込み方法 〕	コーパスの紹介ページ
方 言 日本語諸方言コーパス	COJADS	✓	✓	コーパスの紹介ページ 関連データを「 データ配布 」からダウンロードできます。
日本語学習者 中国語・韓国語母語の日本語学習者縦断発話コーパス	C-JAS	✓	✓	コーパスの紹介ページ プレインテキストは「 データ配布 」からダウンロードできます。
日本語学習者 多言語母語の日本語学習者横断コーパス	I-JAS	✓	✓	コーパスの紹介ページ プレインテキスト・音声・作文は「 データ配布 1 」からダウンロードできます。 I-JAS 外国語母語話者コーパス (I-JAS FOLAS) は「 データ配布 2 」からダウンロードできます。

Access

- ▶ You will first need to create a Chunagon account
- ▶ Then you can apply for specific corpora

SMS

※指定された携帯電話の電話番号に登録コードが送られます。

※登録コードを **SMS** で受け取る場合、**1週間ほど**かかります。

The registration code will be sent to the specified mobile phone number.

If you choose to receive the registration code via **SMS**, it will take **about one week**.

▼ 利用申込はこちらから Apply Here

登録コードをショートメッセージで受け取る
Receive the registration code via SMS



OR

封書（密封的信） Postal Mail

※封書（密封的信）が受け取れる正確な住所が必要です。

※登録コードを**封書（密封的信）**で受け取る場合、**2週間以上**かかります。

Provide a complete, accurate postal address.

If you choose to receive the registration code via **mail**, it will take **two weeks or more**.


▼ 利用申込はこちらから Apply Here

登録コードを郵便（封書）で受け取る
Receive the registration code via Postal Mail



Logging in

- ▶ Once you have access, you can login on this page:



コーパス検索アプリケーション

中納言 コーパス検索アプリケーション

ご利用の際は下記よりログインして下さい。

メールアドレス (ユーザ名) *

hanikatto@icloud.com

パスワード *

.....

※パスワードを忘れた方は[こちら](#)


ログイン

■ 全館停電による各種サービス停止のお知らせ (2月13日～16日)

Copyright © National Institute for Japanese Language and Linguistics.

What is KOTONOHA?

- ▶ Use it to quickly compare/search across corpora at a high level
- ▶ Let's try...



Let's use CEJC

- ▶ Try searching the following terms. Did you have any issues?

❖ パソコン

❖ である

❖ かっこいい

CEJC 中納言

chunagon.ninjal.ac.jp/cejc/search

日本語日常会話コーパス CEJC

中納言 2.7.2 データバージョン

コーパス検索アプリケーション

日本語日常会話コーパス CEJC

短単位検索 長単位検索 文字列検索 位置検索

短単位検索

検索フォームで検索

前方共起条件の追加

キー -- 1 語 キーの条件を指定しない

書字形出現形 が 短単位の条件の追加

後方共起条件の追加

検索対象 設定を隠す

検索対象を選択 検索対象をクリア

全て

検索動作 設定を隠す

文脈中の区切り記号 | 文脈中の発話単位区切り記号 # 前後文脈の語数 20

共起条件の範囲 発話単位境界をまたがない

ダウンロードオプション 設定を表示する

検索

検索結果を


Let's use CEJC

- ▶ Try searching the following terms. Did you have any issues?

❖ パソコン

❖ である

❖ かっこいい



The screenshot shows the CEJC (Japanese Daily Conversation Corpus) search interface in a web browser. The browser tab is labeled 'CEJC 中納言' and the address bar shows 'chunagon.ninjal.ac.jp/cejc/search'. The page title is '日本語日常会話コーパス CEJC'. The interface includes a search bar with a magnifying glass icon and a button '検索フォームで検索'. Below the search bar, there are tabs for '短単位検索' (Short Unit Search), '長単位検索' (Long Unit Search), '文字列検索' (Text Search), and '位置検索' (Position Search). The '短単位検索' tab is active. The search form includes a dropdown for '前方共起条件の追加' (Add anterior co-occurrence conditions), a search key input field with a dropdown, a dropdown for '1', a dropdown for '語' (word), and a checkbox for 'キーの条件を指定しない' (Do not specify key conditions). There is also a dropdown for '書字形出現形' (Character shape appearance form) and a button for '短単位の条件の追加' (Add short unit conditions). Below the search form, there are sections for '検索対象' (Search target) and '検索動作' (Search action). The '検索対象' section has buttons for '検索対象を選択' (Select search target), '検索対象をクリア' (Clear search target), and a '全て' (All) button. The '検索動作' section has a dropdown for '文脈中の区切り記号' (Delimiter in context), a dropdown for '文脈中の発話単位区切り記号' (Delimiter in context for utterance unit), a dropdown for '前後文脈の語数' (Number of words in context), and a dropdown for '共起条件の範囲' (Range of co-occurrence conditions). There is also a button for 'ダウンロードオプション' (Download options) and a link to '設定を表示する' (Show settings).

Let's use CEJC

- ▶ Try searching the following terms. Did you have any issues?

❖ パソコン

❖ である

❖ かっこいい

▼ 前方共起条件の追加

キー

--

1

語

☐ キーの条件を指定しない

書字形出現形

が

で

短単位の条件の追加

後方共起1

キーから

1

語

☐ キーと結合して表示

書字形出現形

が

ある

短単位の条件の追加

▲ 後方共起条件の追加

Let's use CEJC

- ▶ Try searching the following terms. Did you have any issues?

❖ パソコン

❖ である

❖ かっこいい

▼ 前方共起条件の追加

キー 1 語 ☐ キーの条件を指定しない

書字形出現形 ☐ 短単位の条件の追加

後方共起1 キーから 1 語 ☐ キーと結合して表示

書字形出現形 ☐ 短単位の条件の追加

▲ 後方共起条件の追加

▼ 前方共起条件の追加

キー 1 語 ☐ キーの条件を指定しない

書字形出現形 ☐ 短単位の条件の追加

後方共起1 キーから 1 語 ☐ キーと結合して表示

書字形出現形 ☐ 短単位の条件の追加

▲ 後方共起条件の追加

Let's use CEJC

- ▶ Of course, this is made easier using the multi-text search bar

The screenshot shows the CEJC search interface in a web browser. The browser tab is labeled 'CEJC 中納言' and the address bar shows 'chunagon.ninjal.ac.jp/cejc/search'. The page title is '日本語日常会話コーパス CEJC'. The interface includes a search bar with the text '中納言 コーパス検索アプリケーション' and '日本語日常会話コーパス CEJC'. Below the search bar are four tabs: '短単位検索', '長単位検索' (selected), '文字列検索', and '位置検索'. The '長単位検索' tab is active, showing a search form with a search bar containing 'かっこいい', a '検索' button, and a '検索フォームで検索' button. Below the search bar are options for '前方共起条件の追加' and '後方共起条件の追加'. The search form also includes a 'キー' dropdown menu, a '書字形出現形' dropdown menu, and a '長単位の条件の追加' button. The '検索対象' section includes a '検索対象を選択' button, a '検索対象をクリア' button, and a '全て' button. The '検索動作' section includes a '文脈中の区切り記号' dropdown menu, a '文脈中の発話単位区切り記号' dropdown menu, a '前後文脈の語数' dropdown menu, and a '共起条件の範囲' dropdown menu. The 'ダウンロードオプション' section is also visible.



Let's use CEJC

- ▶ What if I wanted to look for expressions like the following:

よくない

ご飯

野球選手

良ければ

飲んだりして

お寿司

かもしれない

行っ__



Case study: Calculate Collocations

- ▶ We want to know how L1 Japanese speakers use the phrase じゃ in idle chit-chat.
- ▶ After you locate all instances of this phrase, export the file and calculate/observe the following:
 - ❖ What POS typically comes before じゃ? After?
 - ❖ What bigram/trigram collocations exist with this phrase?
 - ❖ What do these results tell us about じゃ?



Q&A

- ▶ Any questions or comments?